



Računarski fakultet

MASTER RAD

TT-GS - Rasterizacija 3D
Gaussian Splatting algoritma
na Tenstorrent hardveru

Vanja Kovinić

M 11/2024

Mentor:

dr Nemanja Ilić

Komisija:

dr Nemanja Ilić

dr Nevena Marić

dr Goran Rakočević

Beograd, jul 2026.

Sadržaj

1	Uvod	2
1.1	Motivacija	2
1.2	Doprinosi i struktura rada	3

1 Uvod

1.1 Motivacija

Fotografija prikazuje scenu iz tačno jedne perspektive, dok posmatrač po pravilu želi upravo suprotno - slobodu da se kroz tu istu scenu kreće. Premošćivanje tog jaza, odnosno rekonstrukcija 3d prostora iz skupa fotografija, tako da kasnije scenu možemo posmatrati iz proizvoljnog ugla, jedan je od temeljnih problema računarske grafike/računarskog vida i naziva se *novel view synthesis*. Decenijama je ovaj zadatak počivao na eksplicitnim geometrijskim reprezentacijama (*polygonal meshes* i *point clouds*) koje se teško nose sa složenim materijalima (*materials*), providnošću i sitnim detaljima poput dlake ili lišća.

Prekretnicu je donela **NeRF** [1] metoda (engl. *neural radiance fields*), koja prizor predstavlja *implicitno*, kao neprekidnu funkciju koju aproksimira višeslojni perceptron. Ta funkcija svakoj tački u prostoru i svakom pravcu gledanja pridružuje boju i gustinu, a slika se formira integraljenjem duž zraka koji prolaze kroz scenu (engl. *volume rendering*). **NeRF** postiže fotorealistične rezultate, ali po visokoj ceni: renderovanje jednog piksela zahteva stotine evaluacija neuralne mreže duž odgovarajućeg zraka, zbog čega je izvorna metoda daleko od interaktivne brzine, dok se i sam postupak treninga meri u satima, a radi se po sceni.

3D Gaussian Splatting [2] (**3DGS**) rešava upravo ovaj problem brzine tako što napušta implicitnu reprezentaciju i prizor opisuje eksplicitno - skupom od više miliona anizotropnih 3D Gausovih raspodela ¹ (u nastavku: *Gausijana*), od kojih svaka nosi svoj položaj, kovarijansu, boju i providnost. Umesto skupe obrade zrakova, slika se dobija *rasterizacijom*: Gausijani se projektuju na ravan slike, sortiraju po dubini i potom stapaju u konačnu boju piksela *alpha blending* algoritmom. Time se dobijaju interaktivne brzine (preko 30 fps) uz kvalitet uporediv sa najboljim varijantama **NeRF**-a, što je **3DGS** učinilo dominantnom metodom u oblasti.

¹Anizotropne Gausove raspodele su Gausove raspodele koje imaju različite varijanse za različite pravce.

Ono što je zajedničko i NeRF-u i, posebno, 3DGS-u jeste da su osmišljeni i implementirani gotovo isključivo za GPU kartice (CUDA), uz lakše varijante namenjene vebu (WebGL/WebGPU). Sam postupak renderovanja čvrsto je vezan za SIMT model izvršavanja grafičkih procesora (engl. *Single Instruction, Multiple Threads*), u kome veliki broj niti sinhrono izvršava isti program nad različitim podacima. U međuvremenu se pojavila nova klasa hardvera namenjenog veštačkoj inteligenciji - takozvani *protočni* (engl. *dataflow*) akceleratori - koja počiva na bitno drugačijim načelima: eksplicitnom, programski upravljanom kretanju podataka, odsustvu deljene memorije i SIMT izvršavanja, te računu organizovanom oko pločica (engl. *tiles*) i širokih vektorskih jedinica. Akcelerator Wormhole kompanije Tenstorrent istaknut je predstavnik te klase, a skorašnji radovi počeli su da na njega preslikavaju numeričke i naučne proračune — simulacije sistema od N tela [3], brze Furijeove transformacije [4] i druge numeričke jezgre [5]. Ipak, renderovanje polja zračenja - i grafička rasterizacija uopšte - do sada nije bilo preslikano ni na jedan ovakav akcelerator.

Upravo taj jaz motiviše ovaj rad. Pitanje koje postavljamo glasi: može li se računski najzahtevniji deo 3DGS renderovanja efikasno preslikati na protočni akcelerator i da li je takvo rešenje konkurentno postojećima. Iza-zov nije mali - algoritam je nepravilan, oslanja se na rasuto čitanje i upis podataka (engl. *scatter/gather*) i na suštinski sekvencijalno stapanje sortiranih Gausijana po svakom pikselu, što se ne uklapa očigledno u protočni model zamišljen pre svega za guste linearno-algebarske operacije. Rad je stoga koncipiran kao *studija izvodljivosti*: ograničavamo se na prolaz unapred, odnosno na renderovanje unapred obučene scene, bez obuke i bez diferencijabilne rasterizacije, dok najskuplju fazu - alfa stapanje - implementiramo kao namensko jezgro za Tenstorrent hardver.

1.2 Doprinosi i struktura rada

Doprinosi ovog rada mogu se sažeti u nekoliko tačaka:

- **Jezgro za alfa stapanje na Tenstorrent hardveru.** Implementirano je tt-metal jezgro koje izvršava alfa stapanje 3DGS prizora na akceleratoru Wormhole. Prema našim saznanjima, reč je o prvoj

komponenti sistema za renderovanje polja zračenja koja je preslikana na protočni akcelerator.

- **Okruženje za poređenje triju izvršnih podloga** (engl. *backend*). Razvijena je hibridna arhitektura cevovoda u kojoj se projekcija, dodela pločica i sortiranje izvršavaju na procesoru, dok se alfa stapanje prepušta izabranoj podlozi. Tri podloge - CPU (referentna implementacija u okruženju PyTorch), CUDA (postojeće rešenje na grafičkom procesoru) i Tenstorrent — izložene su kroz jedinstven interfejs, što omogućava njihovo neposredno poređenje pod istim uslovima.
- **Raspoređivanje opterećenja po pravilu najdužeg posla (LPT)**. Budući da je broj Gausijana po pločici izrazito neravnomeran, naivna podela pločica po jezgrima dovodi do toga da ukupno vreme renderovanja diktira najopterećenije jezgro. Predložena je shema raspoređivanja zasnovana na pravilu najdužeg posla (engl. *Longest-Processing-Time first*), koja osetno ujednačava opterećenje jezgara.
- **Niz algoritamskih optimizacija**. Postupno se uvode prilagođavanja referentnog algoritma osobenostima hardvera — aproksimativna eksponencijalna funkcija na vektorskoj (SFPU) jedinici, odsecanje doprinosa Gausijana zanemarljive providnosti i ograničavanje poluprečnika - uz analizu zašto je svako od njih korisno baš na ovoj arhitekturi.

Zajedno, ova rešenja dovode do toga da prebacivanje alfa stapanja na Wormhole ostvaruje ubrzanje od preko $20\times$ u odnosu na referentnu CPU implementaciju (detaljno u poglavlju 5). Analiza uskih grla pritom otkriva da, kada se stapanje jednom prebaci na akcelerator, preostale faze na procesoru i prenos podataka između domaćina i uređaja postaju novo usko grlo - što neposredno motiviše pravce daljeg rada.

Ostatak rada organizovan je na sledeći način. Poglavlje 2 izlaže teorijske osnove 3D Gaussian Splatting-a: reprezentaciju prizora, parametrizaciju kovarijanse, projekciju iz tri u dve dimenzije i izvođenje jednačine alfa stapanja koju jezgro implementira. Poglavlje 3 predstavlja arhitekturu Tenstorrent hardvera i njegov programski model. Poglavlje 4 opisuje dizajn i implementaciju rešenja - preslikavanje na Tensix jezgra, LPT raspoređivanje i optimizacione tehnike. Poglavlje 5 donosi eksperimentalne rezultate

i poređenje izvršnih podloga, dok poglavlje 6 sumira zaključke i ocrtava pravce budućeg rada.

Literatura

- [1] Ben Mildenhall et al. “NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis”. In: *Proceedings of the European Conference on Computer Vision (ECCV)*. 2020.
- [2] Bernhard Kerbl et al. “3D Gaussian Splatting for Real-Time Radiance Field Rendering”. In: *ACM Transactions on Graphics* 42.4 (2023). DOI: 10.1145/3592433.
- [3] Jenny Lynn Almerol et al. “Accelerating Gravitational N -Body Simulations Using the RISC-V-Based Tenstorrent Wormhole”. In: *Proceedings of the SC '25 Workshops of the International Conference for High Performance Computing, Networking, Storage and Analysis*. 2025. DOI: 10.1145/3731599.3767528.
- [4] Nick Brown, Jake Davies, and Felix LeClair. *Exploring Fast Fourier Transforms on the Tenstorrent Wormhole*. RISC-V for HPC Workshop, ISC High Performance. 2025. arXiv: 2506.15437 [cs.DC].
- [5] Maya Taylor et al. *Numerical Kernels on a Spatial Accelerator: A Study of Tenstorrent Wormhole*. 2026. arXiv: 2603.23343 [cs.PF].