



Računarski fakultet

MASTER RAD

TT-GS - Rasterizacija 3D
Gaussian Splatting algoritma
na Tenstorrent hardveru

Vanja Kovinić

M 11/2024

Mentor:

dr Nemanja Ilić

Komisija:

dr Nemanja Ilić

dr Nevena Marić

dr Goran Rakočević

Beograd, jul 2026.

Sadržaj

1	Uvod	2
1.1	Motivacija	2
1.2	Doprinosi i struktura rada	3

1 Uvod

1.1 Motivacija

Fotografija prikazuje scenu iz tačno jedne perspektive, dok posmatrač po pravilu želi upravo suprotno - slobodu da se kroz tu istu scenu kreće. Premošćivanje tog jaza, odnosno rekonstrukcija 3d prostora iz skupa fotografija, tako da kasnije scenu možemo posmatrati iz proizvoljnog ugla, jedan je od temeljnih problema računarske grafike/računarskog vida i naziva se *novel view synthesis*. Decenijama je ovaj zadatak počivao na eksplicitnim geometrijskim reprezentacijama (*polygonal meshes* i *point clouds*) koje se teško nose sa složenim materijalima (*materials*), providnošću i sitnim detaljima poput dlake ili lišća.

Prekretnicu je donela **NeRF** [1] metoda (engl. *neural radiance fields*), koja prizor predstavlja *implicitno*, kao neprekidnu funkciju koju aproksimira višeslojni perceptron. Ta funkcija svakoj tački u prostoru i svakom pravcu gledanja pridružuje boju i gustinu, a slika se formira integraljenjem duž zraka koji prolaze kroz scenu (engl. *volume rendering*). **NeRF** postiže fotorealistične rezultate, ali po visokoj ceni: renderovanje jednog piksela zahteva stotine evaluacija neuralne mreže duž odgovarajućeg zraka, zbog čega je izvorna metoda daleko od interaktivne brzine, dok se i sam postupak treninga meri u satima, a radi se po sceni.

3D Gaussian Splatting [2] (**3DGS**) rešava upravo ovaj problem brzine tako što napušta implicitnu reprezentaciju i prizor opisuje eksplicitno - skupom od više miliona anizotropnih 3D Gausovih raspodela ¹ (u nastavku: *Gausijana*), od kojih svaka nosi svoj položaj, kovarijansu, boju i providnost. Umesto skupe obrade zrakova, slika se dobija *rasterizacijom*: Gausijani se projektuju na ravan slike, sortiraju po dubini i potom stapaju u konačnu boju piksela *alpha blending* algoritmom. Time se dobijaju interaktivne brzine (preko 30 fps) uz kvalitet uporediv sa najboljim varijantama **NeRF**-a, što je **3DGS** učinilo dominantnom metodom u oblasti.

¹Anizotropne Gausove raspodele su Gausove raspodele koje imaju različite varijanse za različite pravce.

Ono što je zajedničko i **NeRF**-u i, posebno, **3DGS**-u jeste da su osmišljeni i implementirani za GPU kartice (**CUDA** programski jezik), uz lakše varijante namenjene vebu (**WebGL/WebGPU**). Sam postupak renderovanja čvrsto je vezan za **SIMT** (engl. *Single Instruction, Multiple Threads*) model izvršavanja grafičkih procesora, u kome veliki broj niti sinhrono izvršava isti program nad različitim podacima. U međuvremenu se pojavila nova klasa čipova - akceleratora namenjenih veštačkoj inteligenciji (u nastavku: *ML čipovi*) - koji su optimizovani za izvršavanje modela mašinskog učenja.

Tenstorrentov *Blackhole* čip jedan je takav čip. Kako je reč o novom hardveru, tek počinju da se pojavljuju radovi koji ispituju njegove performanse na različitim zadacima [3, 4, 5], dok renderovanje nije među njihovim primarnim namenama.

Konkretno, postavlja se pitanje: može li se računski najzahtevniji deo 3DGS renderovanja efikasno izvršiti na ML čipu i da li je takvo rešenje konkurentno postojećim? Rad se ograničava na prolaz unapred (engl. *forward pass*), odnosno na renderovanje već istrenirane scene, bez podrške za diferencijabilnu rasterizaciju i treniranje scene od nule.

1.2 Doprinosi i struktura rada

Doprinosi ovog rada mogu se sažeti u nekoliko tačaka:

- **Kernel za *alpha blending* na Tenstorrent hardveru.**

Implementiran je **tt-metal** kernel koje izvršava *alpha blending* deo 3DGS algoritma na Tenstorrent hardveru. To je prva implementacija 3DGS algoritma na Tenstorrent čipu.

- **Poređenje 3 različitih *backend-a***

Poređenje performansi 3 različitih *backend-a*: CPU, GPU i Tenstorrent.

- ***Longest-Processing-Time first (LPT) raspoređivanje zadataka.***

Budući da je broj Gausijana po *tile*-u izrazito neravnomeran, naivna podela *tile*-ova po jezgrima dovodi do toga da ukupno vreme renderovanja diktira najopterećenije jezgro. Umesto toga, implementacija je zasnovana na pravilu najdužeg posla (engl. *Longest-Processing-Time first*), koja osetno ujednačava opterećenje jezgara.

Zajedno, ova rešenja dovode do ubrzanja od preko $20\times$ u odnosu na CPU implementaciju.

Literatura

- [1] Ben Mildenhall et al. “NeRF: Representing Scenes as Neural Radiance Fields for View Synthesis”. In: *Proceedings of the European Conference on Computer Vision (ECCV)*. 2020.
- [2] Bernhard Kerbl et al. “3D Gaussian Splatting for Real-Time Radiance Field Rendering”. In: *ACM Transactions on Graphics* 42.4 (2023). DOI: 10.1145/3592433.
- [3] Jenny Lynn Almerol et al. “Accelerating Gravitational N -Body Simulations Using the RISC-V-Based Tenstorrent Wormhole”. In: *Proceedings of the SC '25 Workshops of the International Conference for High Performance Computing, Networking, Storage and Analysis*. 2025. DOI: 10.1145/3731599.3767528.
- [4] Nick Brown, Jake Davies, and Felix LeClair. *Exploring Fast Fourier Transforms on the Tenstorrent Wormhole*. RISC-V for HPC Workshop, ISC High Performance. 2025. arXiv: 2506.15437 [cs.DC].
- [5] Maya Taylor et al. *Numerical Kernels on a Spatial Accelerator: A Study of Tenstorrent Wormhole*. 2026. arXiv: 2603.23343 [cs.PF].